
بسم الله الرحمن الرحيم

دانشگاه صنعتی أصفهان

دانشکده مهندسی برق و کامپیوتر

تشخیص اشیاء و تخمین عمق فاصله با استفاده از الگوریتم‌های یادگیری عمیق

امیر مهدی اسلامی

استاد راهنما : دکتر صفایانی

زمستان ۱۴۰۴

فهرست مطالب

چکیده : ۷

فصل اول مقدمه ۸

۱-۱سابقه و اهمیت موضوع ۸

فصل دوم تحلیل و بررسی روش ها و مشکلات ۱۰

۲-۱ تحلیل و بررسی مشکلات و چالش‌ها ۱۰

۲-۲ مقایسه روش‌های مختلف ۱۱

فصل سوم بررسی روش های استفاده شده ۱۴

۳-۱ استفاده از مدل YOLO برای تشخیص اشیاء ۱۴

۳-۲ استفاده از MobilNet به‌عنوان انکدر در مدل TST ۱۸

۳-۳ استفاده از Connection Module در مدل TST ۲۰

۳-۴ استفاده از Decoder ۲۴

۳-۵ جزییات پیاده‌سازی در مدل TST ۲۸

۳-۶ استفاده از دیتاست NYU Depth برای آموزش مدل ۳۰

۳-۷ محاسبه و استفاده از Loss در مدل TST ۳۴

۳-۸ استفاده از متریک‌ها برای ارزیابی مدل در تخمین عمق ۳۶

فصل چهارم نتایج ۴۴

۴-۱ تحلیل نتایج ۴۵

۴-۲ نتیجه‌گیری ۴۶

فصل پنجم نتیجه‌گیری و پیشنهادات برای تحقیقات آینده ۴۷

۵-۱ نتیجه گیری ۴۷
۵-۲ پیشنهادات برای تحقیقات آینده..... ۴۷
۵-۳ نتیجه گیری کلی..... ۴۹

فهرست اشکال

شکل ۲-۱ انواع معماری ها..... ۱۳

شکل ۳-۱ معماری YOLOv۱۳..... ۱۶

شکل ۳-۲ تصاویر پیش بینی الگوریتم YOLOv۱۳..... ۱۷

شکل ۳-۳ معماری TST ۲۴

شکل ۳-۴معماری SFF ۲۷

شکل ۳-۵ معماریdecoder..... ۲۸

شکل ۳-۶ بعضی از تصاویر دیتاست ۳۳

شکل ۳-۷ حذف outliers و پیدا کردن عمق شی پیدا شده ۴۳

چکیده :

این پروژه به بررسی استفاده از ترکیب دو تکنولوژی تشخیص اشیاء و برآورد عمق تک‌چشمی[1] برای بهبود توانمندی‌های ربات‌ها و سیستم‌های خودران می‌پردازد. در این راستا، از مدل YOLOv13 برای تشخیص اشیاء و از مدل TST[2] برای برآورد عمق استفاده شده است. مدل TST با بهره‌گیری از اطلاعات جهانی در سطح توکن‌ها و بهینه‌سازی برای اجرا در دستگاه‌های کم‌مصرف، توانسته است عملکرد بهتری نسبت به روش‌های پیشین ارائه دهد. هدف این پروژه، شناسایی دقیق اشیاء و برآورد فاصله آن‌ها با استفاده از یک دوربین RGB تنها، به‌ویژه در دستگاه‌های با محدودیت منابع، است. نتایج آزمایش‌ها نشان می‌دهد که این ترکیب قادر است در دستگاه‌هایی نظیر NVIDIA Jetson Nano و TX2 عملکرد بهینه‌ای ارائه دهد و نتایج دقیق‌تری نسبت به مدل‌های سنتی حاصل کند

[1] *monocular depth estimation*
[2] *Token-Sharing Transformer*

فصل اول مقدمه

۱-۱سابقه و اهمیت موضوع

در دهه‌های اخیر، تشخیص اشیاء و تخمین عمق به دو زمینه بسیار مهم در علوم کامپیوتر و بینایی ماشین تبدیل شده‌اند. این دو حوزه به‌ویژه در کاربردهای مختلفی مانند رباتیک موبایلی، خودروهای خودران، و واقعیت افزوده نقش اساسی دارند. این تکنولوژی‌ها به سیستم‌های هوشمند امکان می‌دهند تا دنیای اطراف خود را درک کرده و در تصمیم‌گیری‌های خود از آن استفاده کنند.

تشخیص اشیاء[۳]

تشخیص اشیاء از تصاویر به فرآیند شناسایی و تعیین محل دقیق اشیاء مختلف در یک تصویر یا ویدئو اطلاق می‌شود. یکی از پیشرفته‌ترین روش‌ها برای انجام این کار استفاده از مدل‌های شبکه عصبی کانولوشنی است که می‌توانند ویژگی‌های پیچیده‌تری از داده‌ها استخراج کنند. به‌ویژه، مدل YOLO یکی از محبوب‌ترین و سریع‌ترین مدل‌های تشخیص اشیاء است که در سال‌های اخیر به پیشرفت‌های چشمگیری دست یافته است. مدل‌های جدیدتر مانند YOLOv13 قادر به انجام تشخیص اشیاء با دقت و سرعت بسیار بالا هستند، به‌طوری که می‌توانند در سیستم‌های تعبیه‌شده[۴] که نیاز به زمان پاسخ کوتاه و منابع محدود دارند، به خوبی عمل کنند. در بسیاری از کاربردها، از جمله خودروهای خودران، سیستم‌های نظارتی، و ربات‌های صنعتی، تشخیص سریع و دقیق اشیاء بسیار اهمیت دارد.

منابع مختلفی به کاربرد YOLO در تشخیص اشیاء اشاره کرده‌اند. به‌طور مثال، در تحقیقاتی که Redmon et al. (۲۰۱۶)انجام داده‌اند، مدل YOLOبه عنوان یکی از سریع‌ترین و دقیق‌ترین مدل‌های تشخیص اشیاء معرفی شده است. نسخه‌های جدیدتر این مدل، مانند YOLOv5 و YOLOv4، بهبودهای چشمگیری در سرعت و دقت داشته‌اند، اما YOLOv13یکی از نسخه‌های جدید این مدل است که به‌ویژه برای دستگاه‌های موبایلی و رباتیک طراحی شده است تا علاوه بر دقت، کارایی بالاتری را در پردازش تصاویر داشته باشد.

[3] Object Detection
[4] embedded systems

تخمین عمق[5]

تخمین عمق، فرآیندی است که در آن فاصله هر نقطه از یک تصویر از دوربین یا منبع تصویر تعیین می‌شود. این کار به‌ویژه در رباتیک و خودروهای خودران اهمیت فراوانی دارد، زیرا تخمین دقیق عمق به سیستم‌ها کمک می‌کند تا موقعیت اشیاء در دنیای واقعی را بهتر درک کرده و تصمیمات دقیقی در زمان واقعی اتخاذ کنند. استفاده از دوربین‌های تک‌لنزی برای تخمین عمق به دلیل ارزان بودن و سادگی نسبت به دیگر حسگرها مانند LiDAR و سنسورهای عمق استریو جذابیت زیادی پیدا کرده است.

در سال‌های اخیر، مدل‌های مبتنی بر شبکه‌های عصبی عمیق برای تخمین عمق از تصاویر تک‌لنزی توسعه یافته‌اند. یکی از این مدل‌ها، TST است که در پژوهشی توسط Dong-Jae Lee et al. (۲۰۲۴) معرفی شده است. این مدل بر اساس معماری ترنسفورمر ساخته شده و از اشتراک توکن جهانی برای بهبود عملکرد در پردازش داده‌ها و تخمین عمق استفاده می‌کند. این معماری به‌ویژه برای دستگاه‌های تعبیه که نیاز به پردازش سریع و دقت بالا دارند، بهینه‌سازی شده است. مدل TSTقادر است که عمق دقیق‌تری را با سرعت بالا و در شرایط محدود سخت‌افزاری ارائه دهد. این مدل در مقایسه با دیگر مدل‌های تخمین عمق مانند FastDepth و GuidedDepth عملکرد بسیار بهتری در نرخ فریم و دقت داشته است.

ترکیب تشخیص اشیاء و تخمین عمق ترکیب تشخیص اشیاء و تخمین عمق به‌ویژه در خودروهای خودران و رباتیک اهمیت زیادی دارد. تشخیص اشیاء به سیستم‌ها کمک می‌کند تا اجسام و موانع را در محیط شناسایی کنند، در حالی که تخمین عمق به آن‌ها این امکان را می‌دهد که فاصله دقیق این اجسام را از خود تعیین کنند. این ترکیب می‌تواند برای مسیر یابی خودران و تصمیم‌گیری هوشمند در ربات‌ها بسیار مفید باشد. به‌طور مثال، زمانی که یک خودرو خودران می‌خواهد مانعی را شناسایی کند، ابتدا باید آن را شناسایی کرده (تشخیص اشیاء) و سپس باید مسافت آن را تا خود مشخص کند (تخمین عمق) با استفاده از مدل YOLOv13 برای تشخیص اشیاء و مدل TST برای تخمین عمق، می‌توان این دو فرآیند را به‌صورت همزمان و با دقت و سرعت بالا انجام داد. در این پروژه، هدف ترکیب این دو تکنولوژی است تا سیستمی دقیق و کارآمد برای کاربردهای دنیای واقعی ایجاد شود.

[5] Depth Estimation

فصل دوم تحلیل و بررسی روش ها و مشکلات

۲-۱ تحلیل و بررسی مشکلات و چالش‌ها

در این پروژه، دو مسئله اصلی وجود دارد که در آن‌ها چالش‌های فراوانی در پیاده‌سازی و دقت مدل‌ها وجود دارد : تشخیص اشیاء و برآورد عمق تک‌چشمی در ادامه، هر کدام از این چالش‌ها و مشکلات مرتبط با آن‌ها به تفصیل بررسی خواهند شد.

چالش‌های تشخیص اشیاء

تشخیص اشیاء به‌ویژه در تصاویر با شرایط محیطی مختلف، از جمله تغییرات نور، پس‌زمینه‌های شلوغ و زاویه‌های مختلف، از چالش‌های اساسی در سیستم‌های بینایی است. به‌طور خاص، در مدل‌هایی مانند YOLOv13 که برای شناسایی اشیاء استفاده می‌شود، مشکلاتی نظیر کاهش دقت در شرایط پیچیده‌ای همچون نور کم یا وجود اشیاء مشابه در پس‌زمینه وجود دارد که منجر به اشتباهات در شناسایی یا عدم شناسایی اشیاء می‌شود. این مشکلات به‌ویژه در تصاویر با وضوح پایین‌تر یا در محیط‌هایی که دارای نور و شلوغی متغیر هستند، بارزتر خواهند بود.

در مقاله‌ای که به بررسی TST پرداخته شده، این موضوع که مدل‌های مبتنی بر ViT[6] به دلیل قابلیت یادگیری ویژگی‌های جهانی، می‌توانند در شرایط پیچیده عملکرد بهتری داشته باشند، اشاره شده است .با این حال، این نوع مدل‌ها معمولاً نیاز به پردازش بیشتری دارند و به‌ویژه در شرایط پردازش داده‌های پیچیده‌تر، زمان اجرا و مصرف منابع به شکل قابل توجهی افزایش می‌یابد. به همین دلیل، یکی از چالش‌های این پروژه کاهش مصرف منابع پردازشی با حفظ دقت بالا است، به‌ویژه زمانی که مدل‌های تشخیص اشیاء باید در دستگاه‌های کم‌مصرف اجرا شوند.

چالش‌های برآورد عمق تک‌چشمی

[6] Vision transformer

یکی دیگر از چالش‌های مهم این پروژه، تخمین عمق تنها از یک تصویر RGB است. برآورد عمق، به‌ویژه با استفاده از مدل‌های تک‌چشمی، از آنجا که اطلاعات زیادی از فاصله و عمق اشیاء در تصویر وجود ندارد، دشوار است. در این راستا، مدل‌هایی که برای برآورد عمق طراحی شده‌اند معمولاً از شبکه‌های عصبی پیچشی [۷] استفاده می‌کنند که قادر به یادگیری ویژگی‌های محلی هستند اما برای گرفتن اطلاعات جهانی نیازمند بهبود هستند. اخیراً استفاده از ViT در این حوزه افزایش یافته است که اجازه می‌دهد تا اطلاعات جهانی بهتر پردازش شود

در این فصل، از این رویکردها برای کاهش چالش‌ها و بهبود عملکرد در دستگاه‌های کم‌مصرف استفاده شده است. اهداف اصلی این بخش، بهبود دقت مدل‌ها در شرایط پیچیده و افزایش کارایی مدل‌ها در دستگاه‌های تعبیه‌شده است که با توجه به معماری‌های جدید و بهینه‌شده می‌توان به نتایج بهتری دست یافت.

۲-۲ مقایسه روش‌های مختلف

در این بخش، به بررسی و مقایسه روش‌های مختلف برای تشخیص اشیاء و برآورد عمق تک‌چشمی پرداخته می‌شود. با توجه به پیشرفت‌های اخیر در استفاده از ViT در این حوزه، دو دسته‌بندی اصلی برای معماری‌های مبتنی بر ترنسفورمری و روش‌های ترکیبی با CNN وجود دارد. در ادامه، این دو دسته به‌طور دقیق‌تر بررسی می‌شوند.

۱ .روش‌های مبتنی بر ViT

اخیراً، استفاده از ترنسفورمرها در تخمین عمق تک‌چشمی توجه زیادی را جلب کرده است. ترنسفورمرها به دلیل قابلیت یادگیری اطلاعات جهانی و ویژگی‌های طولانی‌مدت در داده‌ها، از جمله روش‌های اصلی برای بهبود دقت برآورد عمق به شمار می‌آیند. مدل‌هایی مانند DepthFormer و DPT از ترنسفورمر برای پردازش اطلاعات به‌صورت گسترده استفاده کرده‌اند

با این حال، ترنسفورمرها به دلیل داشتن پارامترهای فراوان و پیچیدگی محاسباتی بالای عملیات توجه به خود ، معمولاً زمان بیشتری برای پردازش و منابع بیشتری برای اجرا نیاز دارند. این ویژگی موجب می‌شود که استفاده از این مدل‌ها

[7] CNN

در دستگاه‌های کم‌مصرف مانند سیستم‌های تعبیه‌شده دشوار باشد. در پروژه‌های مبتنی بر لبه ی دستگاه ، این مشکلات به‌ویژه مشهود هستند، چرا که باید هر دو دقت و سرعت پردازش به‌طور همزمان حفظ شود.

۲. معماری‌های ترکیبی شبکه های پیچشی و ترنسفورمی

برای کاهش پیچیدگی محاسباتی ترنسفورمرها، برخی از روش‌ها به ترکیب ترنسفورمرها با شبکه های پیچشی پرداخته‌اند. معماری‌هایی مانند Segforme و ترنسفورمر از شبکه های پیچشی به‌عنوان ویژگی‌بردار [8] استفاده می‌کنند و سپس از ترنسفورمر برای پردازش این ویژگی‌ها بهره می‌برند

.این روش‌ها معمولاً به دو دسته تقسیم می‌شوند:

- معماری‌های سلسله مراتب محور: این معماری‌ها به‌طور تدریجی وضوح توکن‌ها را کاهش می‌دهند تا مدل بتواند ویژگی‌های سطح بالا را یاد بگیرد و از ویژگی‌های جهانی بهره ببرد. این معماری‌ها دقت بالاتری دارند زیرا توانایی یادگیری اطلاعات جهانی از چندین سطح ویژگی را دارند.
- معماری‌های متمرکز بر تنگناها: در این نوع معماری‌ها، ترنسفورمر تنها روی توکن‌های با وضوح پایین تمرکز می‌کند، که باعث کاهش پیچیدگی محاسباتی و بهبود سرعت پردازش می‌شود. هرچند این روش‌ها عملکرد کمتری از نظر دقت دارند، اما از نظر سرعت پردازش بهتر عمل می‌کنند.

۳. معماری پیشنهادیTST

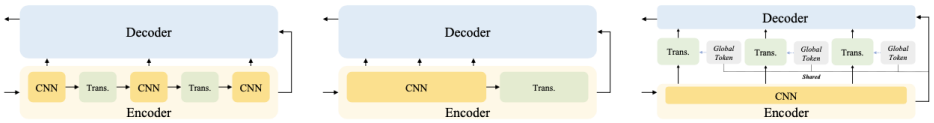
در مقاله‌ای که به بررسی TST پرداخته شده است، ترکیب مزایای هر دو معماری بالا در نظر گرفته شده است .مدل TSTبا استفاده از یک شبکه ی پیچشی سبک برای استخراج ویژگی‌های چندسطحی[9] و یک توکن سراسری

[8] feature extractor
[9] multi-level features

مشترک برای به اشتراک گذاشتن اطلاعات جهانی طراحی شده است. این توکن جهانی به‌طور مؤثر ویژگی‌های جهانی را به ویژگی‌های محلی وارد می‌کند و به‌این‌ترتیب اطلاعات جهانی را به مدل منتقل می‌کند.

این معماری، که از توجه متقابل[10] برای پردازش استفاده می‌کند، به‌ویژه در دستگاه‌های با منابع محدود مانند Jetson بسیار کارآمد است. مدل TST توانسته است عملکرد بهتری در مقایسه با روش‌های موجود ارائه دهد، چرا که در مقایسه با مدل‌های مبتنی بر ترنسفورمر، منابع پردازشی کمتری مصرف کرده و سرعت پردازش بالاتری دارد. نتایج آزمایش‌ها نشان می‌دهند که مدل TST می‌تواند در شرایط مختلف دقت بالاتر و سرعت پردازش بهتری ارائه دهد.

در این مقایسه، روش‌های مبتنی بر ترنسفورمر به دلیل قدرت پردازش ویژگی‌های جهانی و اطلاعات بلندمدت در داده‌ها مطرح شده‌اند، اما چالش‌هایی مانند مصرف بالای منابع و پیچیدگی محاسباتی، استفاده از آن‌ها را در دستگاه‌های کم‌مصرف محدود کرده است. از طرفی، معماری‌های ترکیبی پیچشی ترانسفورمی و مدل‌های سبک‌تر مانند TST توانسته‌اند این چالش‌ها را به‌خوبی حل کنند و عملکرد بهتری در دستگاه‌های کم‌مصرف ارائه دهند.



(a) Hierarchy-focused architecture (b) Bottleneck-focused architecture (c) The proposed architecture

شکل ۲-۱ انواع معماری ها

[10] Cross-attention

فصل سوم بررسی روش های استفاده شده

۳-۱ استفاده از مدل YOLOv13 برای تشخیص اشیاء

در این پروژه، از مدل YOLOv13 برای تشخیص اشیاء استفاده شده است. این مدل یکی از جدیدترین نسخه‌های مجموعه مدل‌های YOLO است که در زمینه تشخیص اشیاء در زمان واقعی از دقت و سرعت بالایی برخوردار است. YOLOv13به‌ویژه برای کاربردهایی که نیاز به شناسایی سریع و دقیق اشیاء در تصاویر دارند، بهینه‌سازی شده است. در این بخش، معماری این مدل و مزایای استفاده از آن در پروژه توضیح داده خواهد شد.

معماری YOLOv13

معماری YOLOv۱۳ به گونه‌ای طراحی شده است که بتواند به‌طور همزمان عملکرد دقیق و سرعت بالایی داشته باشد. این مدل با استفاده از روش‌های نوآورانه‌ای مانند بهبود تطبیقی همبستگی مبتنی بر گراف[11] و تجمیع و توزیع کامل در خط لوله [12] می‌تواند همزمان ویژگی‌های محلی و جهانی تصاویر را به‌خوبی شناسایی کرده و اطلاعات مهم را از بین ویژگی‌های مختلف استخراج کند.

۱. بهبود همبستگی تطبیقی مبتنی بر ابرگراف:این مکانیزم به مدل YOLOv۱۳ این امکان را می‌دهد که به‌طور خودکار ارتباطات پیچیده و بالادستی بین ویژگی‌های مختلف تصویر را شبیه‌سازی و تقویت کند. در مدل‌های قبلی YOLO ، تنها ارتباطات جفتی بین ویژگی‌ها مدنظر قرار می‌گرفت که توانایی مدل را برای شبیه‌سازی ارتباطات پیچیده‌تر محدود می‌کرد. با استفاده از HyperACE، این مدل قادر به درک ارتباطات پیچیده‌تر بین اشیاء مختلف در تصویر است، حتی زمانی که این اشیاء در مقیاس‌ها و موقعیت‌های مختلف ظاهر شوند.

[11] HyperACE
[12] FullPAD

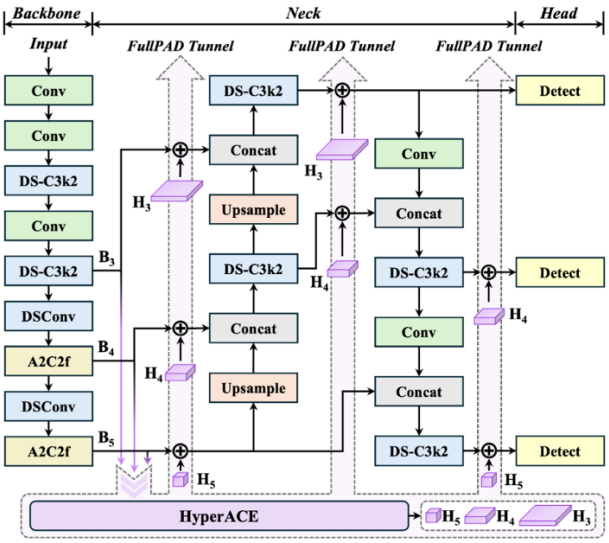
۲. تجمیع و توزیع کامل در خط لوله یکی دیگر از ویژگی‌های کلیدیYOLOv13 ، استفاده از معماری FullPADاست که امکان انتشار ویژگی‌های تقویت‌شده در سراسر شبکه را فراهم می‌آورد. این پارادایم باعث می‌شود که اطلاعات از طریق شبکه به‌طور مؤثری توزیع شده و ارتباطات و ویژگی‌های موجود در تصویر به‌خوبی ترکیب شوند تا دقت مدل در تشخیص اشیاء در شرایط پیچیده به‌طور قابل توجهی بهبود یابد.

۳. استفاده پیچش‌های جداشدنی عمقی[۱۳]:یکی دیگر از نوآوری‌های YOLOv۱۳ استفاده از پیچشی های جداشدنی عمقی برای کاهش هزینه محاسباتی و پارامترهای مدل است. این تکنیک به مدل کمک می‌کند که پردازش سریع‌تر و بهینه‌تری انجام دهد، بدون اینکه از دقت آن کاسته شود. در این روش، ویژگی‌ها به‌طور جداگانه از هر کانال پردازش می‌شوند که باعث کاهش حجم محاسبات و بهبود عملکرد مدل در دستگاه‌های کم‌مصرف می‌شود.

۴. ساختار مدلYOLOv13 :

- Backbone: این بخش شامل شبکه‌ای است که ویژگی‌های اولیه از تصویر ورودی استخراج می‌کند.
- Neck: این بخش مسئول ادغام ویژگی‌ها از چندین مقیاس مختلف است و آن‌ها را برای پردازش در قسمت‌های بعدی آماده می‌کند.
- Head: بخش نهایی است که تصمیم‌گیری نهایی برای تشخیص اشیاء را انجام می‌دهد.

[13] *Depthwise Separable Convolutions*



شکل ۳-۱ معماری YOLOv13

چرا از YOLOv13 استفاده شد؟

مدل YOLOv13 به دلیل ویژگی‌های برجسته‌ای که دارد برای این پروژه انتخاب شده است:

۱. دقت بالا در شناسایی اشیاء :یکی از اصلی‌ترین دلایل استفاده از YOLOv13 در این پروژه، دقت بالای آن در شناسایی اشیاء در تصاویر با شرایط پیچیده مانند پس‌زمینه شلوغ و نور کم است. مدل YOLOv13 توانایی شبیه‌سازی ارتباطات پیچیده بین اشیاء مختلف را دارد که باعث افزایش دقت آن در شرایط غیرخطی می‌شود.

۲. عملکرد در زمان واقعی :این مدل به‌طور خاص برای پردازش سریع تصاویر در زمان واقعی طراحی شده است. از آنجا که این پروژه نیاز به شناسایی اشیاء و تخمین عمق در زمان واقعی دارد، استفاده از YOLOv13 که عملکرد بالایی در این زمینه دارد، بسیار منطقی است.

۳. کارایی در دستگاه‌های کم‌مصرف :از آنجا که پروژه در دستگاه‌هایی با منابع محدود مانند Jetson پیاده‌سازی می‌شود، استفاده از YOLOv13 که با استفاده از تکنیک‌های HyperACE و FullPAD

می‌تواند به‌طور مؤثری از منابع استفاده کند، باعث بهینه‌سازی عملکرد مدل در دستگاه‌های کم‌مصرف می‌شود.

۴. کاهش پیچیدگی محاسباتی :استفاده از پیچشی های جدا شدنی عمقی و HyperACE در YOLOv13 باعث شده که مدل بتواند با پارامترهای کمتر و هزینه محاسباتی پایین‌تر عملکرد بهتری نسبت به مدل‌های قبلی داشته باشد.

در نهایت، انتخاب این مدل به‌عنوان مدل تشخیص اشیاء برای این پروژه به دلیل توانایی بالای آن در شناسایی دقیق اشیاء در تصاویر پیچیده و همچنین کارایی بالا در دستگاه‌های کم‌مصرف، انتخابی مؤثر و بهینه بوده است.



شکل ۳-۲ تصاویر پیش بینی الگوریتم YOLOv13

۳-۲ استفاده از MobilNetv2 به‌عنوان انکدر در مدل TST

در این پروژه، از MobilNetv2 به‌عنوان انکدر برای مدل TSTاستفاده شده است. انتخاب این مدل به دلایل مختلفی صورت گرفته که در ادامه به جزئیات معماری و علت استفاده از آن پرداخته خواهد شد.

۱. معماری MobilNetv2

معماری MobilNetv2 که به‌عنوان انکدر در این پروژه استفاده شده، یکی از مدل‌های کارآمد و سبک است که برای دستگاه‌های کم‌مصرف طراحی شده است. مدل MobilNetv2 به‌ویژه برای پردازش تصاویر در سیستم‌های تعبیه‌شده با منابع محدود بسیار مناسب است.

۱.۱. بلوک باقی مانده ی معکوس

یکی از ویژگی‌های اصلی MobilNetv2 استفاده از بلوک‌های باقی مانده ی معکوس است که طراحی بسیار کارآمدی دارند. این بلوک‌ها به این صورت عمل می‌کنند که ابتدا ویژگی‌ها را از طریق یک لایه پیچشی تفکیک پذیر عمقی پردازش می‌کنند و سپس ویژگی‌های استخراج‌شده را از طریق لایه‌های ۱X۱پیچشی به ابعاد جدید تبدیل می‌کنند. این معماری به‌طور ویژه برای بهینه‌سازی پیچیدگی محاسباتی و کاهش نیاز به پارامترهای زیاد طراحی شده است.

- پیچشی های جداشدنی عمقی: در این نوع کانوولوشن، به‌جای انجام کانوولوشن‌های کامل برای تمامی کانال‌ها، فقط در هر کانال به‌صورت جداگانه کانوولوشن انجام می‌شود که باعث کاهش پیچیدگی محاسباتی و تعداد پارامترها می‌شود.
- Residual Connections: در این مدل، از اتصالات باقی‌مانده استفاده می‌شود که امکان یادگیری بهتر و بهینه‌سازی مدل را فراهم می‌آورد.

۱.۲. ساختار مدل انکدر

در مدل TSTEncoder که از MobilNetv2 به‌عنوان انکدر استفاده می‌کند، ویژگی‌های ورودی از طریق مراحل مختلف شبکه پردازش می‌شوند و در نهایت سه مجموعه ویژگی با مقیاس‌های مختلف تولید می‌شود:

- F۱: ویژگی‌ها با مقیاس ۱/۸ تصویر (پردازش جزئی‌تر)
- F۲: ویژگی‌ها با مقیاس ۱/۱۶ تصویر
- F۳: ویژگی‌ها با مقیاس ۱/۳۲ تصویر (پردازش بیشتر)

این ویژگی‌ها از طریق لایه‌های مختلف انکدر از جمله بلوک‌های باقی مانده ی معکوس به‌طور تدریجی کاهش می‌یابند و در نهایت ویژگی‌های مختلفی برای استفاده در مراحل بعدی مدل استخراج می‌شوند.

۲. چرا از MobilNetv2 به‌عنوان انکدر استفاده کردیم؟

استفاده از MobilNetv2 به‌عنوان انکدر برای مدل TST دلایل متعددی دارد:

۱. کارایی بالا در دستگاه‌های کم‌مصرف: MobilNetv2 به طور خاص برای استفاده در دستگاه‌های کم‌مصرف طراحی شده است. این مدل از ویژگی‌های خاصی برای کاهش مصرف محاسبات و سرعت پردازش بهره می‌برد. این ویژگی‌ها باعث می‌شود که مدل در دستگاه‌های با منابع محدود به‌طور مؤثر و سریع عمل کند.

۲. سبک و بهینه‌سازی‌شده :در مقایسه با مدل‌های دیگر مانند ResNet یا VGG ، MobilNetv2 مدل سبک‌تری است که به کاهش زمان پردازش و تعداد پارامترها کمک می‌کند. این ویژگی‌ها باعث می‌شود که این مدل برای استفاده در سیستم‌های تعبیه‌شده که نیاز به سرعت بالا و مصرف کم دارند، مناسب باشد.

۳. دقت بالا در پردازش ویژگی‌ها: توانسته است دقت بالایی در استخراج ویژگی‌های تصاویر در مقیاس‌های مختلف به‌ویژه در محیط‌های پیچیده با نور کم یا پس‌زمینه شلوغ به‌دست آورد. این ویژگی‌ها در تفسیر و استخراج ویژگی‌های عمق در تصاویر تک‌چشمی بسیار مفید هستند.

۴. انعطاف‌پذیری در مقیاس‌ها MobileNetv2 : قادر است ویژگی‌های مختلف تصویر را در مقیاس‌های مختلف استخراج کرده و آن‌ها را برای استفاده در مراحل بعدی بهینه کند. این انعطاف‌پذیری در مقیاس‌ها به

مدل این امکان را می‌دهد که ویژگی‌های با دقت بالا در مقیاس‌های مختلف استخراج کند و سپس این ویژگی‌ها را برای مراحل دیگر پردازش آماده کند.

۵. سازگاری با مدل‌های ترنسفورمری:با توجه به اینکه مدل TST از ترنسفورمر برای یادگیری اطلاعات جهانی و ویژگی‌های محلی استفاده می‌کند، استفاده از MobileNetv2 به‌عنوان انکدر باعث می‌شود که ویژگی‌های سطح پایین‌تر به‌طور مؤثر به مدل وارد شوند. این مدل قابلیت خوبی در ایجاد ترکیب‌هایی از ویژگی‌های محلی و جهانی برای پیش‌بینی عمق فراهم می‌آورد.

۳. توضیحات بیشتر در مورد انکدر

۱. تعریف لایه‌های کمکی :تابع conv_bn_actکه یک لایه کانوولوشن به همراه batch normalization و تابع فعال‌سازی ReLue6ایجاد می‌کند. این لایه‌ها برای پردازش و بهبود ویژگی‌های ورودی به‌کار می‌روند.

۲. ساختار لایه های باقی مانده ی معکوس:این کلاس به‌عنوان بلوک اصلی انکدر استفاده می‌شود و از ترکیب کانوولوشن‌های جدا برای کاهش پیچیدگی محاسبات و بهبود کارایی استفاده می‌کند. استفاده از این ساختار باعث می‌شود که مدل قادر به پردازش ویژگی‌ها با دقت بالا و در عین حال با سرعت بالا باشد.

۳. پیاده‌سازی مراحل مختلف: در مدل TST، ویژگی‌های مختلف در سه مرحله پردازش می‌شوند این ساختار باعث می‌شود که ویژگی‌ها در مقیاس‌های مختلف استخراج شده و برای استفاده در توجه متقابلو دیکدر به‌طور مؤثر آماده شوند.

۳-۳ استفاده از ماژول اتصال در مدل ما

در مدل TSTکه برای تخمین عمق تک‌چشمی استفاده شده است،ماژول های وصل نقش مهمی در یادگیری اطلاعات جهانی و ترکیب آن با ویژگی‌های محلی دارد. این بخش از مدل مسئول پیوند ویژگی‌های استخراج‌شده از

انکدر با ترنسفورمر است، که از آن برای تقویت پیش‌بینی عمق استفاده می‌شود. در ادامه، جزئیات کد ماژول اتصال و دلایل استفاده از آن در این مدل توضیح داده خواهد شد.

۱. ساختار و عملکرد ماژول اتصال

مدل ما از یک ساختار پیچیده استفاده می‌کند که در آن بخش‌های مختلف مدل از جمله انکدر، ترنسفورمر و دیکدر به‌طور مؤثری با هم تعامل دارند. این تعامل از طریق بخش ماژول اتصال انجام می‌شود که در آن ویژگی‌های محلی و جهانی ترکیب می‌شوند تا عمق نهایی پیش‌بینی شود.

۱.۱لایه‌های توجه متقابل[۱۴]

لایه‌ی اصلی در ماژول های اتصال ، لایه توجه متقابل است که در آن دو نوع توکن مختلف به هم متصل می‌شوند:

- توکن‌های محلی :این توکن‌ها ویژگی‌هایی هستند که از تصویر استخراج شده‌اند و ویژگی‌های سطح پایین‌تر را نشان می‌دهند.
- توکن‌های جهانی :این توکن‌ها اطلاعات بیشتری از تصویر دارند و به‌طور کلی شامل ویژگی‌های سطح بالاتر هستند که از مقیاس‌های مختلف استخراج شده‌اند.

در این لایه، از توجه متقابل استفاده می‌شود تا اطلاعات موجود در توکن‌های محلی و توکن‌های جهانی (که به‌طور مشترک به‌عنوان توکن‌های سطح بالا به مدل وارد می‌شوند) به هم ارتباط داده شوند. این فرآیند به مدل این امکان را می‌دهد که ویژگی‌های دقیق‌تر و غنی‌تری از تصویر برای تخمین عمق استخراج کند.

۱.۲عملکرد توجه متقابل

در کد شما، لایه‌ی توجه متقابل به‌طور خاص برای اجرای این فرآیند طراحی شده است. در این لایه:

- Q (Query): از ویژگی‌های محلی استخراج می‌شود.
- K (Key)و V (Value): از ویژگی‌های جهانی استخراج می‌شوند.

[14] Cross-attention

سپس، ماتریس توجه با محاسبه تشابه بین query و key به‌دست می‌آید. بعد از محاسبه‌ی این ماتریس، از آن برای وزن‌دهی به ویژگی‌های value استفاده می‌شود و این ویژگی‌ها ترکیب می‌شوند تا ویژگی‌های جدیدی که اطلاعات دقیق‌تری دارند، ایجاد شوند.

۱.۳ شبکه ی پیشخور[15]

پس از مرحله‌ی توجه متقابل، خروجی به یک شبکه پیشخور می‌رود. این لایه از یک کانوولوشن نقطه‌ای با کرنل ۳ و یک لایه کانوولوشن برای بهبود دقت و کاهش پیچیدگی محاسباتی استفاده می‌کند. در این مدل، FFN به‌طور خاص برای کاهش هزینه‌های محاسباتی در هنگام یادگیری ویژگی‌های دقیق از توکن‌ها طراحی شده است.

۱.۴عملکرد کلی TokenSharingConnection

در نهایت، این معماری که از ترکیب لایه‌های توجه متقابل و FFNLite استفاده می‌کند، ویژگی‌های استخراج‌شده از انکدر را ترکیب می‌کند. این لایه‌ها به‌طور مؤثر ویژگی‌های محلی و جهانی را برای دیکدر ارسال می‌کنند تا عمق پیش‌بینی شده به‌طور دقیق‌تری بازسازی شود.

در این بخش از مدل، ویژگی‌های سطح پایین (مثل ویژگی‌های F۱ از مقیاس ۱/۸) از طریق لایه‌های adaptive average pooling به مقیاس‌های بالاتر مانند F۳ (مقیاس ۱/۳۲) کاهش می‌یابند تا مقیاس‌های مشابه با توکن‌های جهانی ایجاد شوند. این کار باعث می‌شود که مدل بتواند اطلاعات جهانی را به ویژگی‌های محلی وارد کند و دقت پیش‌بینی عمق را افزایش دهد.

۲. دلایل استفاده از ماژول اتصال در مدلTST

دلایل استفاده از ماژول اتصال در مدل TST بر اساس اهداف و چالش‌هایی که در مقاله مطرح شده است، عبارتند از:

۲.۱کاهش پیچیدگی محاسباتی

[15] Feed-forward networks

یکی از چالش‌های اصلی در استفاده از ترنسفورمر، هزینه محاسباتی بالای آن به‌ویژه در پردازش ویژگی‌های جهانی است. برای کاهش این هزینه، ماژول اتصال به‌گونه‌ای طراحی شده است که فقط توکن‌های با وضوح پایین‌تر توکن محلی در فرآیند توجه به خودخیل باشند. این کار باعث کاهش هزینه‌های محاسباتی می‌شود، در حالی که هنوز می‌توان ویژگی‌های غنی‌تری از تصاویر به‌دست آورد.

۲.۲. افزایش دقت تخمین عمق

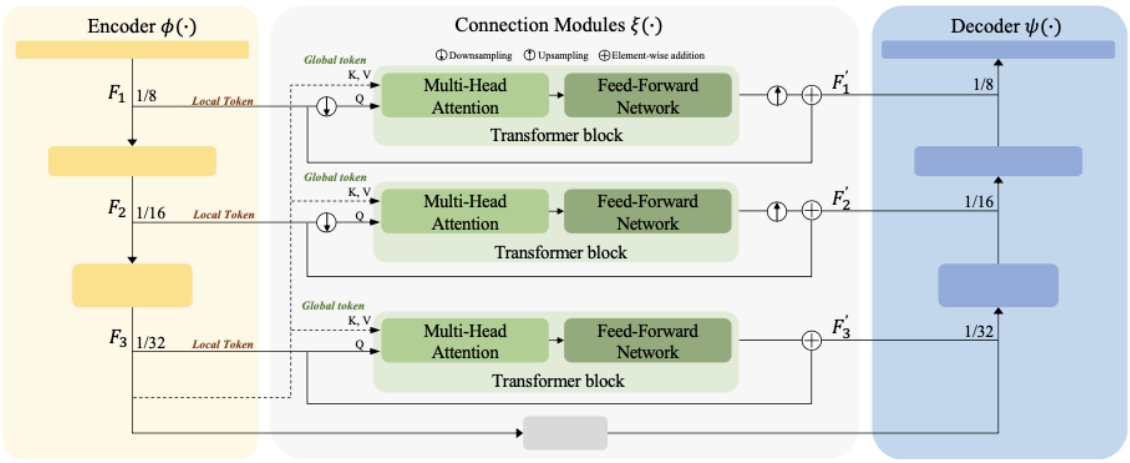
با استفاده از توجه متقابل ، مدل می‌تواند اطلاعات جهانی را که از ویژگی‌های سطح بالا استخراج می‌شود، به ویژگی‌های محلی وارد کند. این کار باعث می‌شود که مدل قادر به یادگیری اطلاعات دقیق‌تری از عمق اشیاء باشد. به عبارت دیگر، از آنجایی که اطلاعات جهانی به ویژگی‌های محلی اضافه می‌شود، پیش‌بینی عمق به‌طور دقیق‌تری انجام می‌شود.

۲.۳ارتباط مؤثر بین ویژگی‌های محلی و جهانی

Connection Module به‌طور خاص طراحی شده است تا این ارتباط مؤثر را برقرار کند. از آنجا که ویژگی‌های محلی به‌طور مستقل از ویژگی‌های جهانی پردازش می‌شوند، وجود توجه متقابل باعث می‌شود که ویژگی‌های محلی در زمینه اطلاعات جهانی پردازش شوند. این فرآیند باعث می‌شود که مدل از ویژگی‌های غنی‌تری استفاده کرده و به‌طور دقیق‌تری پیش‌بینی عمق را انجام دهد.

۲.۴بهینه‌سازی برای دستگاه‌های کم‌مصرف

در این مدل، از لایه‌های ساده و سبک استفاده شده است تا مدل بتواند در دستگاه‌های کم‌مصرف مانند Jetson با سرعت بالا اجرا شود. استفاده از این معماری سبک باعث می‌شود که پیچیدگی محاسباتی کاهش یابد و در عین حال دقت پیش‌بینی عمق حفظ شود. این کار به‌ویژه در کاربردهایی مانند رباتیک و خودروهای خودران بسیار مفید است.



شکل ۳-۳ معماری TST

۳-۴ استفاده از دیکدر

در این پروژه، برای دیکدر از مدل GLPDepth و به‌ویژه از ماژول Selective Feature [۱۶]و دیکدر چندمقیاسه استفاده شده است که عملکرد بالایی را با پیچیدگی محاسباتی کمتر ارائه می‌دهد. در ادامه، جزئیات کد دیکدر و دلایل استفاده از آن بر اساس مقاله و ساختار کلی توضیح داده می‌شود.

۱. ماژول ادغام انتخابی ویژگی ها[۱۷]

در دیکدر، یکی از اجزای مهم که برای ادغام ویژگی‌های محلی و جهانی از آن استفاده می‌شود، ماژول (SFF) است. این ماژول به‌ویژه برای کمک به ادغام ویژگی‌ها از مقیاس‌های مختلف و تقویت ویژگی‌های مهم طراحی شده است. عملکرد این ماژول در مدل TST به شرح زیر است:

۱.۱. ساختار ماژول SFF:

[16] SFF
[17] SFF

- ادغام ویژگی‌ها :ابتدا ویژگی‌های محلی و جهانی که از انکدر استخراج شده‌اند، با هم ترکیب می‌شوند. این ترکیب از طریق عملیات torch.cat در بعد کانال‌ها انجام می‌شود.
- کانوولوشن‌ها و نرمال‌سازی :سپس ویژگی‌های ترکیب‌شده از طریق چند لایه کانوولوشن با Batch Normalization و ReLU عبور می‌کنند تا ویژگی‌ها به‌طور مؤثری پردازش شوند و به سطح بهینه‌ای برای استفاده در مراحل بعدی برسند.
- تولید نقشه توجه :در نهایت، خروجی از طریق لایه‌های کانوولوشن دیگری عبور کرده و با استفاده از تابع سیگموید به دو کانال تقسیم می‌شود. این کانال‌ها به‌عنوان نقشه توجه استفاده می‌شوند که به طور خودکار مشخص می‌کند کدام بخش از ویژگی‌ها برای پیش‌بینی عمق مهم‌تر است.
- ترکیب ویژگی‌ها با نقشه توجه :ویژگی‌های محلی و جهانی سپس با استفاده از نقشه توجه به‌دست‌آمده، ترکیب می‌شوند. این عملیات باعث می‌شود که مدل به‌طور مؤثری به ویژگی‌های مهم‌تر توجه کند و از سایر ویژگی‌های غیرمهم صرف‌نظر کند.

۱.۲. چرا از SFF استفاده کردیم؟

- فناوری ساده و سبک :استفاده از SFF باعث کاهش پیچیدگی محاسباتی و افزایش سرعت پردازش می‌شود، زیرا این ماژول با استفاده از کانوولوشن‌های ساده به‌طور مؤثری ویژگی‌های محلی و جهانی را ترکیب می‌کند.
- افزایش دقت پیش‌بینی :با استفاده از نقشه توجه تولید شده، مدل قادر به تمرکز روی بخش‌های مهم تصویر است و می‌تواند پیش‌بینی عمق دقیق‌تری انجام دهد.

۲. دیکدر GLPDepth :

دیکدر استفاده شده در این پروژه، دیکدر سه‌مقیاسه است که از ویژگی‌های مختلفی با مقیاس‌های مختلف برای پیش‌بینی عمق استفاده می‌کند. این دیکدر به‌طور خاص به‌گونه‌ای طراحی شده است که از ویژگی‌های سطح بالا و پایین برای بازسازی نقشه عمق دقیق‌تر استفاده می‌کند.

۲.۱. ساختار دیکدر:

- مرحله اول :(f۲ <- f۳) در ابتدا، ویژگی‌های سطح بالای f۳ از مقیاس ۳۲/۱ تصویر از طریق یک لایه کانوولوشن به ابعاد پایین‌تری کاهش می‌یابد. سپس این ویژگی‌ها با ویژگی‌های f۲ از مقیاس ۱۶/۱ ترکیب می‌شوند.
- مرحله دوم :(f۱ <- f۲) بعد از آن، ویژگی‌های ترکیب‌شده از مرحله اول با ویژگی‌های f۱ از مقیاس ۸/۱ تصویر ترکیب می‌شوند. این ترکیب به‌طور مؤثری ویژگی‌های محلی و جهانی را در مقیاس‌های مختلف با هم ترکیب می‌کند.
- مرحله نهایی :پس از ترکیب ویژگی‌ها، خروجی از دیکدر به‌طور متوالی از طریق چندین لایه نمونه برداری به اندازه تصویر اصلی بازمی‌گردد. این لایه‌ها از عملیات نمونه برداری دوخطی استفاده می‌کنند تا اندازه ویژگی‌ها به اندازه تصویر ورودی افزایش یابد.

۲.۲.چرا از دیکدر ۳-مقیاسه استفاده کردیم؟

- تقویت جزئیات تصویر :استفاده از ویژگی‌ها در مقیاس‌های مختلف باعث می‌شود که مدل قادر به دریافت اطلاعات دقیق‌تر از تصویر در مقیاس‌های مختلف باشد، که این بهبود در دقت پیش‌بینی عمق را فراهم می‌آورد.
- پردازش اطلاعات چندمقیاسه :با استفاده از دیکدر سه‌مقیاسه، مدل به‌طور مؤثری قادر به یادگیری اطلاعات با مقیاس‌های مختلف است. این ویژگی برای پیش‌بینی عمق در تصاویر پیچیده که اشیاء در مقیاس‌های مختلف ظاهر می‌شوند، بسیار حیاتی است.

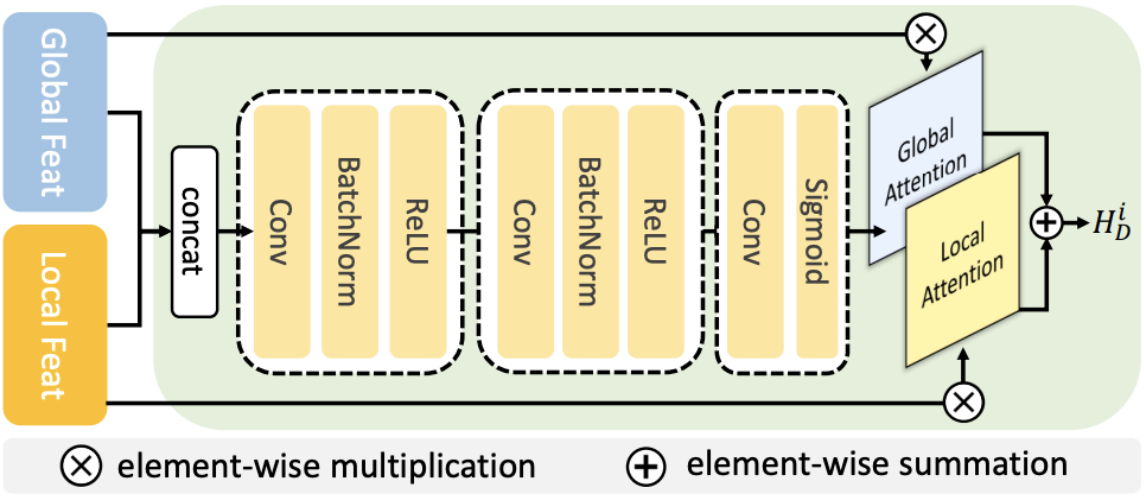
۳. استفاده از SFF در دیکدر

در مقاله‌ای که مدل GLPDepth و دیکدر آن توضیح داده شده است، اشاره شده که استفاده از SFF باعث بهبود پیش‌بینی عمق در مقیاس‌های مختلف می‌شود. این روش اجازه می‌دهد تا ویژگی‌های محلی و جهانی به‌طور مؤثری

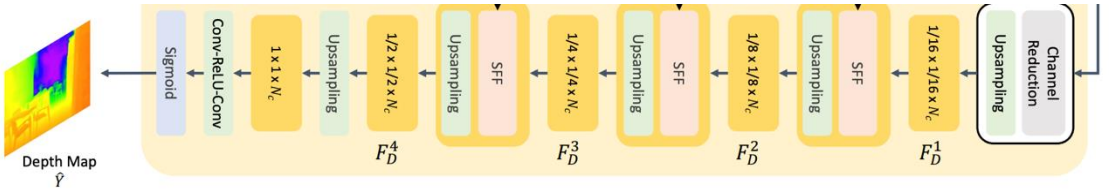
با هم ترکیب شوند و از آنجا که این فرآیند توجه بیشتری به ویژگی‌های مهم می‌کند، نتایج به‌دست‌آمده از دیکدر دقیق‌تر و بهتر خواهند بود.

۴. نتیجه‌گیری

در این بخش از مدل، از SFF و دیکدر ۳-مقیاسه برای تقویت دقت پیش‌بینی عمق استفاده شده است. با توجه به اینکه ویژگی‌های محلی و جهانی با استفاده از توجه متقابل و SFF ترکیب می‌شوند، مدل قادر به استخراج اطلاعات دقیق‌تری از تصاویر می‌شود. این روش به‌ویژه برای پردازش در سیستم‌های کم‌مصرف و بهبود دقت پیش‌بینی عمق در دستگاه‌های تعبیه‌شده بسیار مفید است.



شکل ۳-۴ معماری SFF



شکل ۳-۵ معماری decoder

۳-۵ جزییات پیاده‌سازی در مدل TST

در این بخش، جزییات پیاده‌سازی مدل TST با توجه به توضیحات مربوطه بررسی می‌شود. این پیاده‌سازی شامل مراحل مختلفی است که در انتخاب معماری، تنظیمات آموزش، بهینه‌سازی، و استفاده از تکنیک‌های مختلف مانند افزایش داده ها و زمانبندی نرخ یادگیری توضیح داده شده‌اند.

۱. استفاده از PyTorch برای پیاده‌سازی

مدل پیشنهادی در این مقاله با استفاده از فریم‌ورک PyTorch پیاده‌سازی شده است PyTorch .یکی از فریم‌ورک‌های محبوب برای یادگیری عمیق است که به‌ویژه برای انجام آزمایش‌های سریع و پیاده‌سازی‌های انعطاف‌پذیر شناخته شده است.

۲. تنظیمات بهینه‌سازی و استفاده از ADAM

برای آموزش مدل، ازبهینه ساز ADAM استفاده شده است که یکی از بهینه‌سازهای محبوب در یادگیری عمیق است و به‌خوبی با انواع مختلف شبکه‌ها و داده‌ها کار می‌کند. در این پیاده‌سازی، تنظیمات خاصی برای اندازه ی یادگیری و بتا استفاده شده است:

- بتا:
  - β_1 = ۰.۹: این مقدار به‌طور معمول برای افزایش پایداری در فرآیند بهینه‌سازی استفاده می‌شود.
  - β_2 = ۰.۹۹: این مقدار برای تنظیم میزان حرکت به سمت مقادیر بهینه استفاده می‌شود و به کاهش نوسانات در طول بهینه‌سازی کمک می‌کند.
- اندازه ی یادگیری :

- مقدار ۰.۰۰۰۳ = learning rate انتخاب شده است که از تنظیمات استاندارد برای آموزش این مدل استفاده می‌شود.

- معماری بهینه‌سازی:

- استفاده از Cosine Annealing Warm Restarts برای تنظیم اندازه ی یادگیری برنامه ریزی شده ، که به‌طور خودکار نرخ یادگیری را تغییر می‌دهد تا عملکرد مدل را بهینه کند.

۳. تنظیمات زمانبندی میزان یادگیری

برای تنظیم نرخ یادگیری در طول فرآیند آموزش، از یک روش پیشرفته به نام Cosine Annealing Warm Restarts استفاده شده است. این روش باعث می‌شود که نرخ یادگیری در ابتدا بالا باشد و سپس به تدریج کاهش یابد، که به بهینه‌سازی مدل کمک می‌کند.

- تنظیمات مربوط به زمانبندی:

- $T_0 = ۱۰$: زمان شروع اولین تغییر در نرخ یادگیری.
- $T_{mult} = ۲$: زمانی که تغییرات نرخ یادگیری دو برابر می‌شود.
- $\gamma = ۰.۵$: این پارامتر نشان‌دهنده ضریبی است که نرخ یادگیری را به تدریج کاهش می‌دهد.

در این پیاده‌سازی، مدل برای ۱۴ ایپاک آموزش داده می‌شود.

۵. استفاده از افزایش داده ها

برای افزایش تنوع داده‌ها و جلوگیری از بیش از حد شدنشون در طول آموزش، از تکنیک‌های مختلف افزایش داده ها استفاده می‌شود. این تکنیک‌ها به مدل کمک می‌کنند که بتواند از داده‌های بیشتری برای آموزش استفاده کند، بدون اینکه نیاز به جمع‌آوری داده‌های جدید باشد. تکنیک‌های استفاده‌شده در این پروژه به شرح زیر هستند:

- افزایش روشنایی : تغییر میزان روشنایی تصویر برای بهبود توانایی مدل در تشخیص ویژگی‌ها در شرایط نوری مختلف.
- افزایش کنتراست : تغییر کنتراست تصویر برای کمک به مدل در یادگیری ویژگی‌ها در تصاویر با کنتراست مختلف.
- افزایش هیو و اشباع : تغییر رنگ‌ها و اشباع برای کمک به مدل در شبیه‌سازی شرایط مختلف محیطی.
- افزایش مقدار : تغییر مقادیر روشنایی برای بهبود دقت مدل در شرایط مختلف.

تمامی این تکنیک‌ها با احتمال ۰.۵ برای هر کدام به‌صورت تصادفی اعمال می‌شوند.

۶. استفاده از برش عمودی

یکی از نوآوری‌های این مقاله، استفاده از روش جدید Vertical CutDepth برای داده‌افزایی است. در این روش، بخشی از تصویر با عمق مربوطه به‌صورت عمودی برش داده می‌شود، که کمک می‌کند مدل به ویژگی‌های عمودی و هندسی بهتر توجه کند.

- CutDepth: این تکنیک به‌طور خاص برای عمق‌سنجی طراحی شده است و به مدل کمک می‌کند که به‌طور مؤثری ویژگی‌های عمودی را از تصویر استخراج کرده و پیش‌بینی عمق دقیق‌تری انجام دهد.
- Vertical CutDepth: به جای برش تصادفی در هر دو جهت افقی و عمودی، فقط برش در جهت افقی اعمال می‌شود و این اجازه می‌دهد که مدل به ویژگی‌های عمودی تصویر بیشتر توجه کند.

۳-۶ استفاده از دیتاست NYU Depth V2 برای آموزش مدل

در این پروژه، از دیتاست NYU Depth V۲برای آموزش مدل استفاده شده است. این دیتاست یکی از محبوب‌ترین دیتاست‌ها برای تخمین عمق تک‌چشمی در کامپیوتر بینایی است و شامل تصاویر RGB و عمق متناسب از انواع

مختلف صحنه‌های داخلی می‌باشد. در این بخش، به معرفی و ویژگی‌های این دیتاست پرداخته خواهد شد و توضیحاتی در مورد نحوه استفاده از آن در این پروژه آورده خواهد شد.

۱. معرفی دیتاست NYU Depth V۲

دیتاست NYU Depth V۲ یکی از معتبرترین و بزرگ‌ترین دیتاست‌ها برای تخمین عمق تک‌چشمی است که توسط دانشگاه نیو یورک ارائه شده است. این دیتاست در ابتدا برای آزمایش مدل‌های عمق‌سنجی و رباتیک جمع‌آوری شده است و به‌ویژه برای ارزیابی مدل‌های یادگیری عمیق در زمینه عمق‌سنجی تک‌چشمی مناسب است.

- تصاویر RGB و عمق :این دیتاست شامل تصاویر RGB با رزولوشن ۶۴۰ در ۴۸۰ است که برای هر تصویر، نقشه عمق آن نیز در دسترس است. این نقشه‌های عمق از یک دوربین عمق استخراج شده‌اند.
- صحنه‌های داخلی :این دیتاست عمدتاً شامل صحنه‌های داخلی مانند اتاق‌ها، سالن‌ها، آشپزخانه‌ها و دفاتر است که دارای انواع مختلفی از اشیاء در مقیاس‌های مختلف و در شرایط نوری مختلف هستند.
- تعداد تصاویر :دیتاست NYU Depth V۲ شامل ۱۴۴۹ تصویر RGB و عمق از ۴۶۴ صحنه مختلف است. این تصاویر شامل نماهای مختلف از هر صحنه می‌باشند که برای آموزش و ارزیابی مدل‌ها استفاده می‌شود.
- اطلاعات اضافی :علاوه بر تصاویر و نقشه‌های عمق، NYU Depth V۲ شامل برچسب‌های مختلف برای تقسیم‌بندی تصاویر به کلاس‌های مختلف مانند اجسام و مناطق مختلف نیز می‌باشد که می‌تواند برای مسائل مختلف مانندتشخیص اشیا نیز استفاده شود.

۲. ویژگی‌های کلیدی دیتاست NYU Depth

- دقت بالا :نقشه‌های عمق موجود در این دیتاست دارای دقت بالایی هستند و به‌ویژه برای مدل‌های یادگیری عمیق که به تخمین عمق از یک تصویر RGB نیاز دارند، بسیار مناسب است.
- تنوع صحنه‌ها :تنوع بالای صحنه‌ها و اشیاء موجود در این دیتاست باعث می‌شود که مدل‌ها بتوانند در شرایط مختلف و با اشیاء مختلف آموزش داده شوند.

- چالش‌های موجود :صحنه‌های مختلف این دیتاست معمولاً دارای پیچیدگی‌های بالایی هستند، از جمله تغییرات نوری، پس‌زمینه شلوغ، و اشیاء در مقیاس‌های مختلف که برای آزمایش مدل‌ها در شرایط واقعی بسیار مفید است.

۳. چرا از دیتاست NYU Depth استفاده کردیم؟

در این پروژه، استفاده از دیتاست NYU Depthبه دلایل زیر انتخاب شده است:

۱. معتبر بودن و شهرت :دیتاست NYU Depthیکی از معتبرترین و شناخته‌شده‌ترین دیتاست‌ها در زمینه تخمین عمق تک‌چشمی است و به‌طور گسترده در تحقیقات و مقایسات مدل‌های تخمین عمق استفاده می‌شود. این امر باعث می‌شود که نتایج حاصل از این پروژه مقایسه‌پذیر با نتایج سایر مدل‌های موجود باشد.

۲. تنوع و پیچیدگی صحنه‌ها :دیتاست NYU Depth شامل صحنه‌های مختلف و چالش‌برانگیز است که می‌تواند مدل را برای پردازش شرایط پیچیده‌ای مانند نور کم، پس‌زمینه شلوغ و مقیاس‌های مختلف آماده کند. این تنوع به مدل این امکان را می‌دهد که در موقعیت‌های واقعی عملکرد خوبی داشته باشد.

۳. دقت بالا در نقشه‌های عمق :نقشه‌های عمق موجود در این دیتاست از دقت بالایی برخوردارند که این امر برای آموزش مدل‌های یادگیری عمیق که نیاز به داده‌های با کیفیت دارند، بسیار حیاتی است.

۴. میزان داده‌های کافی برای آموزش و ارزیابی :با داشتن بیش از ۱۴۰۰ تصویر و نقشه عمق، دیتاست NYU Depthبرای آموزش مدل‌های پیچیده مانند TSTداده‌های کافی و متنوع فراهم می‌کند.

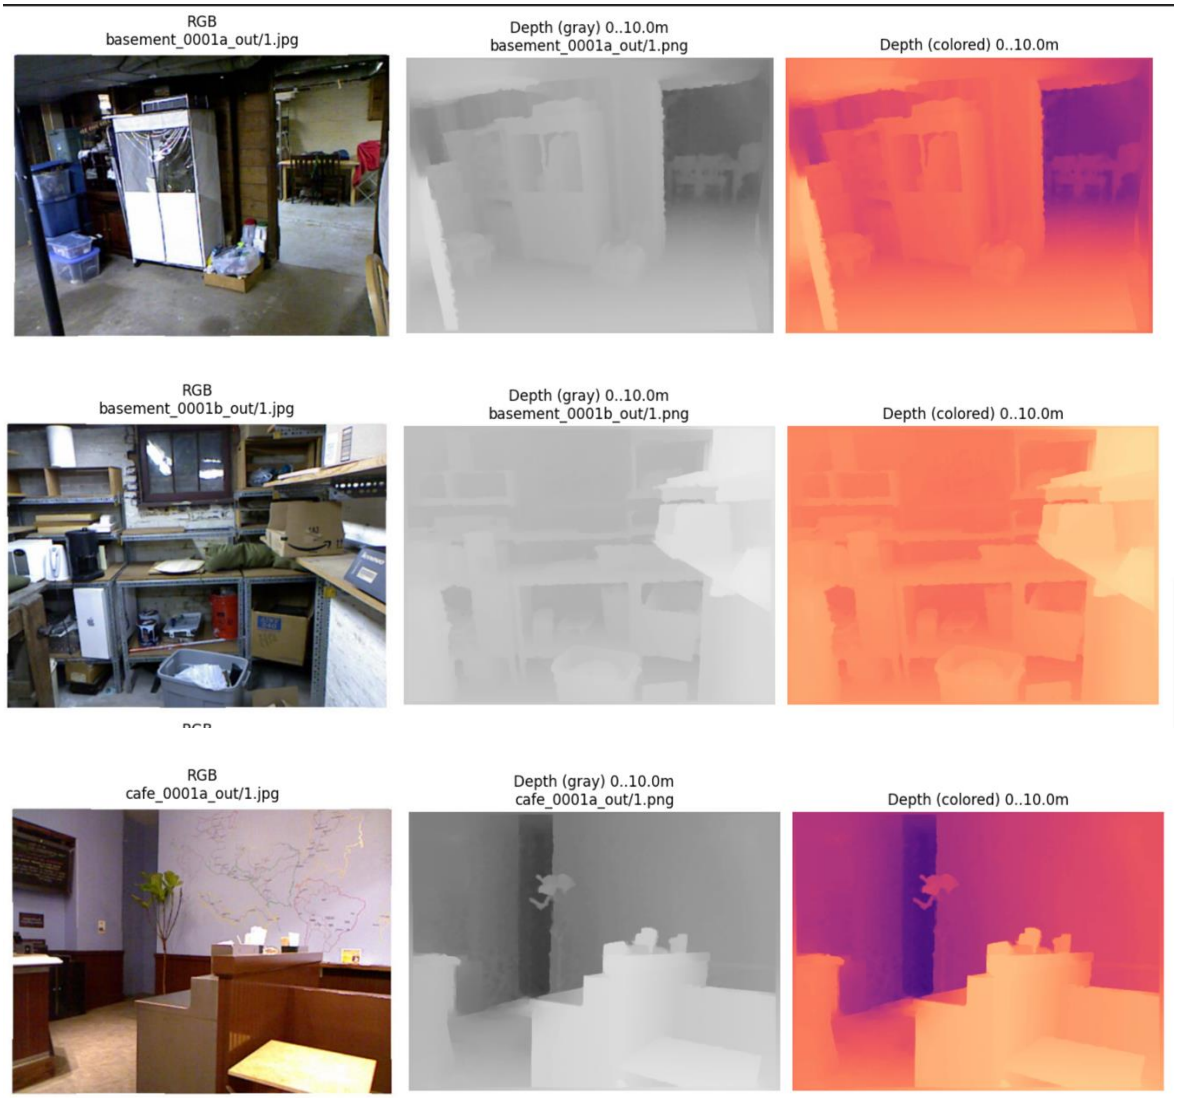
۴. استفاده از دیتاست در این پروژه

برای استفاده از دیتاست NYU Depth در این پروژه، مراحل زیر دنبال شد:

۱. پیش‌پردازش داده‌ها :تصاویر RGB و نقشه‌های عمق از دیتاست NYU Depth بارگذاری و برای آموزش مدل آماده شدند. در این مرحله، اندازه تصاویر به مقیاس مناسب تغییر داده شد و داده‌ها به صورت تصادفی به دسته‌های آموزشی و آزمایشی تقسیم شدند.

۲. آموزش مدل :مدل ترانسفورمر اشتراک گذاری توکن با استفاده از تصاویر RGB و نقشه‌های عمق از دیتاست NYU Depth آموزش داده شد. این آموزش شامل ۱۰۰ ایپاک با استفاده از Adam optimizer و نرخ یادگیری ۰.۰۰۰۳ بود. علاوه بر آن، از تکنیک‌های افزایش داده ها مانند تغییر روشنایی، کنتراست، هیو و چرخش برای افزایش تنوع داده‌ها و جلوگیری از overfitting استفاده شد.

۳. ارزیابی مدل :پس از آموزش، مدل بر روی مجموعه آزمایشی دیتاست NYU Depthارزیابی شد تا دقت پیش‌بینی عمق آن بررسی شود. این ارزیابی شامل معیارهایی مانند AbsRel, RMSE, و $\delta 1$ بود که نشان‌دهنده دقت مدل در پیش‌بینی عمق تصاویر بودند.



شکل ۳-۶ بعضی از تصاویر دیتاست و تبدیل کردن عمق به مقیاس ۰-۱۰ متری و نمایش آن

۳-۷ محاسبه و استفاده از Loss در مدل TST

در این پروژه، برای آموزش مدل ترانسفورمر اشتراک گذاری توکن از یک تابع loss خاص برای تخمین عمق استفاده شده است که در مقاله به‌طور ویژه توضیح داده شده است. تابع loss برای عمق‌سنجی به‌گونه‌ای طراحی شده که بتواند دقت پیش‌بینی عمق را بهبود دهد و مدل را برای پیش‌بینی دقیق‌تر عمق در شرایط مختلف آموزش دهد.

۱. محاسبه Loss

برای آموزش مدل‌های تخمین عمق، از تابع lossمقیاس‌ناپذیر استفاده شده است که حساسیت به تغییرات کوچک در عمق و تفاوت‌های مقیاس‌ها را بهبود می‌دهد. در این پروژه، تابع loss به‌ویژه برای سنجش خطا در پیش‌بینی‌های عمق در مقیاس‌های مختلف تصویر طراحی شده است. این loss به شرح زیر است:

Scale-Invariant Log Scale Loss.۱.۱

در این پروژه، از scale-invariant log scale lossبرای محاسبه تفاوت میان عمق پیش‌بینی‌شده (که توسط مدل TST تولید می‌شود) و عمق واقعی (که از نقشه عمق دیتاست استخراج شده است) استفاده می‌شود. این نوع loss به‌طور خاص برای تخمین عمق مناسب است، زیرا به مدل این امکان را می‌دهد که تغییرات مقیاس در تصاویر مختلف را نادیده بگیرد و تمرکز بیشتری بر پیش‌بینی دقیق‌تر عمق داشته باشد.

فرمول تابع lossبه‌صورت زیر است:

$$L = \frac{1}{n}\sum_{i}\left(d_i^2 - \frac{1}{2n^2}\sum_{i} d_i^2\right)$$

که در آن:

- $d_i = \log(y_i) - \log(\hat{y_i})$

- y_i:عمق واقعی برای پیکسل i
- $\widehat{y_i}$:عمق پیش‌بینی‌شده برای پیکسل i

۱.۲توضیحات بیشتر درباره محاسبه:Loss

- مقیاس لگاریتمی: در این روش از لگاریتم عمق‌ها برای مقایسه استفاده می‌شود. این کار باعث می‌شود که مدل نسبت به مقیاس‌های مختلف عمق حساسیت کمتری داشته باشد و در عوض بر دقت پیش‌بینی تمرکز کند.
- مقیاس ثابت: این ویژگی تابع loss به‌ویژه برای تخمین عمق از یک تصویر تک‌چشمی مفید است، زیرا مقیاس عمق واقعی و پیش‌بینی‌شده در تصاویر مختلف ممکن است متفاوت باشد، اما تابع lossاین تفاوت‌ها را نادیده می‌گیرد.

۲. دلایل استفاده از این نوعLoss

دلایل استفاده از scale-invariant log scale loss به‌طور خاص برای تخمین عمق ذکر شده است که به شرح زیر است:

۱. مناسب بودن برای تخمین عمق تک‌چشمی: تخمین عمق تک‌چشمی با استفاده از یک تصویر RGB یکی از چالش‌های اصلی در بینایی کامپیوتری است. این مشکل معمولاً با خطاهایی در مقیاس همراه است، زیرا تفاوت‌های عمقی در تصاویر مختلف ممکن است به‌طور قابل توجهی تغییر کنند. استفاده از log scale loss به مدل کمک می‌کند تا این تفاوت‌های مقیاس را نادیده بگیرد و تمرکز بیشتری بر پیش‌بینی دقیق‌تری از عمق داشته باشد.

۲. افزایش دقت پیش‌بینی عمق: استفاده از log scale loss به‌ویژه برای تخمین عمق در مناطق با تغییرات زیاد در عمق کمک می‌کند. این روش باعث می‌شود که مدل قادر به یادگیری ویژگی‌های دقیق‌تری از مقیاس‌های مختلف عمق در تصویر باشد.

۳. نرمال‌سازی عمق‌ها: استفاده از لگاریتم عمق‌ها این امکان را می‌دهد که تفاوت‌های کوچک در عمق به‌خوبی شبیه‌سازی شوند، که در غیر این صورت ممکن است در پیش‌بینی عمق از بین بروند. این امر باعث می‌شود که مدل دقت بالاتری در پیش‌بینی عمق در شرایط پیچیده‌ای مانند نور کم یا پس‌زمینه شلوغ داشته باشد.

۴. محاسبات کارآمد: علاوه بر بهبود دقت پیش‌بینی، محاسبات را نیز کارآمدتر می‌کند. این روش از نظر محاسباتی بهینه است و می‌تواند به‌طور مؤثری ویژگی‌های مختلف تصویر را پردازش کند بدون اینکه نیازی به پارامترهای اضافی یا پیچیدگی محاسباتی زیاد باشد.

۳-۸ استفاده از متریک‌ها برای ارزیابی مدل در تخمین عمق

در این پروژه، برای ارزیابی عملکرد مدل اشتراک گذاری توکن در تخمین عمق تک‌چشمی، از چندین متریک رایج در حوزه تخمین عمق استفاده شده است. این متریک‌ها به‌ویژه برای اندازه‌گیری دقت پیش‌بینی عمق مدل و مقایسه آن با مدل‌های دیگر کاربرد دارند. در ادامه، به بررسی این متریک‌ها و نحوه محاسبه آن‌ها می‌پردازیم.

۳.۱ $\delta 1, \delta 2, \delta 3$: نسبت درصدی پیش‌بینی‌های صحیح

این سه متریک نشان‌دهنده درصد پیش‌بینی‌های صحیح مدل هستند که برای هر پیکسل در تصویر محاسبه می‌شوند. به‌طور خاص، این متریک‌ها درصد پیش‌بینی‌هایی را که از مقدار واقعی عمق بیشتر از یک ضریب خاص انحراف دارند، نشان می‌دهند.

- $\delta 1$: درصد پیش‌بینی‌هایی که عمق پیش‌بینی‌شده کمتر از ۱.۲۵ برابر عمق واقعی است.
- $\delta 2$: درصد پیش‌بینی‌هایی که عمق پیش‌بینی‌شده کمتر از 1.25^2 برابر عمق واقعی است.
- $\delta 3$: درصد پیش‌بینی‌هایی که عمق پیش‌بینی‌شده کمتر از 1.25^3 برابر عمق واقعی است.

این سه متریک به‌طور کلی نشان‌دهنده دقت پیش‌بینی مدل در برابر تغییرات مقیاس عمق هستند. مدل‌هایی که نسبت‌های بالاتری در این متریک‌ها دارند، عملکرد بهتری در پیش‌بینی عمق از خود نشان می‌دهند.

فرمول این متریک‌ها به صورت زیر است:

$$\delta_n = \frac{1}{N}\sum_{i=1}^{N} \max\left(\frac{\hat{y}_i}{y_i}, \frac{y_i}{\hat{y}_i}\right)^n$$

که در آن:

- $\hat{y}_i$ عمق پیش‌بینی‌شده برای پیکسل i
- y_i عمق واقعی برای پیکسل i
- n برابر با ۱، ۲ یا ۳ بسته به متریک مورد نظر است.

۲.AbsRel : خطای نسبی مطلق

این متریک یکی از مهم‌ترین متریک‌ها در تخمین عمق است که میزان خطای نسبی پیش‌بینی‌ها را به‌طور متوسط اندازه‌گیری می‌کند. این متریک حساسیت مدل را نسبت به تغییرات کوچک در عمق ارزیابی می‌کند.

فرمول محاسبه AbsRel به‌صورت زیر است:

$$\text{AbsRel} = \frac{1}{N}\sum_{i=1}^{N} \frac{|\,\hat{y}_i - y_i\,|}{y_i}$$

که در آن:

- $\hat{y}_i$ عمق پیش‌بینی‌شده برای پیکسل i
- y_i عمق واقعی برای پیکسل i

این متریک اندازه‌گیری می‌کند که پیش‌بینی‌های مدل به‌طور متوسط چه مقدار از عمق واقعی فاصله دارند. مقدار کمتر این متریک نشان‌دهنده دقت بالاتر مدل است.

۳. ریشه مربع خطای میانگین

این متریک برای اندازه‌گیری خطای مربعی پیش‌بینی‌های مدل به‌کار می‌رود .به‌ویژه زمانی مفید است که بخواهیم ارزیابی کنیم که پیش‌بینی‌ها به طور کلی چقدر از عمق واقعی فاصله دارند. این متریک بیشتر خطاهای بزرگ را جریمه می‌کند.

فرمول محاسبه به‌صورت زیر است:

$$\mathrm{RMSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2}$$

که در آن:

- $\hat{y}_i$ عمق پیش‌بینی‌شده برای پیکسل i
- y_i عمق واقعی برای پیکسل i

این متریک نشان می‌دهد که به‌طور کلی پیش‌بینی‌ها چه میزان خطا دارند. مدل‌هایی که RMSE کمتری دارند، دقت بالاتری دارند.

۴. $\log 10$: خطای لگاریتمی

این متریک برای اندازه‌گیری اختلافات در مقیاس‌های مختلف عمق استفاده می‌شود. با محاسبه اختلافات لگاریتمی بین عمق پیش‌بینی‌شده و عمق واقعی، می‌توان ارزیابی کرد که مدل چقدر در پیش‌بینی مقادیر بزرگ عمق و تغییرات مقیاس دقیق است.

فرمول محاسبه $\log ۱۰$به‌صورت زیر است:

$$\log 10 = \frac{1}{N}\sum_{i=1}^{N} \log_{10}\left(\frac{\hat{y}_i}{y_i}\right)$$

که در آن:

- $\hat{y}_i$ عمق پیش‌بینی‌شده برای پیکسل i
- y_i عمق واقعی برای پیکسل i

این متریک به‌طور خاص برای مقایسه عمق در مقیاس‌های مختلف و تشخیص دقت مدل در پیش‌بینی‌های دقیق‌تر برای عمق‌های بیشتر مفید است.

دلایل استفاده از این متریک‌ها

در مقاله توضیح داده شده است که استفاده از این متریک‌ها برای ارزیابی عملکرد مدل‌های تخمین عمق بسیار حیاتی است زیرا:

- $\delta 1, \delta 2, \delta 3$ نشان‌دهنده قدرت مدل در پیش‌بینی عمق با دقت بالا در مقیاس‌های مختلف است و به‌ویژه در ارزیابی مدل‌هایی که نیاز به پردازش اطلاعات در مقیاس‌های مختلف دارند، مفید هستند.
- AbsRel به مدل این امکان را می‌دهد که دقت پیش‌بینی عمق را در سطح جزئیات (در مقیاس‌های مختلف) اندازه‌گیری کند.
- RMSE به‌طور مؤثری اندازه‌گیری می‌کند که مدل در پیش‌بینی‌های عمق چقدر خطا دارد و این متریک برای ارزیابی کلی پیش‌بینی‌ها استفاده می‌شود.
- Log10 برای اندازه‌گیری دقت مدل در مقیاس‌های مختلف عمق و ارزیابی تفاوت‌ها در پیش‌بینی‌های مختلف عمق بسیار مفید است.

این متریک‌ها کمک می‌کنند تا عملکرد مدل به‌طور جامع ارزیابی شود و به محققان و توسعه‌دهندگان این امکان را می‌دهند که نقاط قوت و ضعف مدل را شناسایی کرده و آن را بهبود دهند.

۳-۹ ترکیب کردن دو معماری با همدیگر

در این پروژه، دو مؤلفه اصلی با یکدیگر ترکیب شدند:

۱. معماری تشخیص شیء برای شناسایی اشیاء و استخراج جعبه محدودکننده هر شیء در تصویر رنگی

۲. اطلاعات عمق برای تخمین فاصله هر شیء از دوربین

ایده اصلی این بود که خروجی YOLO به‌عنوان ناحیه موردنظر روی نقشه عمق اعمال شود و سپس با تحلیل مقادیر عمق داخل همان ناحیه، فاصله شیء برآورد گردد.

روند کلی روش پیشنهادی

۱) انتخاب تصویر و هم‌ترازی RGB و عمق

ابتدا یک فریم از دیتاست انتخاب شد.
از آنجا که تصاویر RGB و نقشه‌های عمق ممکن است هنگام خواندن فایل دچار جابه‌جایی ابعاد یا چرخش شوند، ابتدا هم‌راستاسازی بین تصویر RGB و نقشه ی عمق پیش بینی شده انجام شد تا مختصات پیکسلی در هر دو فضا متناظر باشند.

این مرحله بسیار مهم است؛ چون در غیر این صورت bbox های تشخیص‌داده‌شده روی ناحیه اشتباه از نقشه ی عمق اعمال می‌شوند.

۲) تشخیص اشیاء

تصویر RGB به مدل YOLO داده شد و برای هر شیء:

- کلاس شیء

- مقدار اطمینان
- مختصات جعبه محدودکننده (x_1, y_1, x_2, y_2)

استخراج شد.

به این ترتیب، معماری YOLO نقش محل‌یابی شیءرا بر عهده گرفت.

۳) استخراج عمق متناظر با هر شیء

برای هر bbox خروجی YOLO ، ناحیه متناظر از نقشه ی عمق برش داده شد:

$$D_{bbox} = D[y_1 : y_2, x_1 : x_2]$$

که در آن:

- D نقشه عمق کل تصویر است
- D_{bbox} مجموعه مقادیر عمق داخل جعبه محدودکننده شیء است

در این مرحله، تعداد پیکسل‌های داخل bbox نیز محاسبه شد:

$$N_{total} = | D_{bbox} |$$

۴) حذف مقادیر نامعتبر

قبل از تخمین فاصله، ابتدا پیکسل‌های نامعتبر حذف شدند:

- مقادیر خالی
- مقادیر Inf

- مقادیر صفر

بنابراین مجموعه اولیه عمق معتبر به شکل زیر تعریف شد:

$$\mathcal{V} = \{d \in D_{bbox} \mid d \text{ finite} \wedge d > 0\}$$

۵) حذف Outlier ها از عمق داخل bbox

به دلیل وجود نویز سنسور عمق، لبه‌ها، و همچنین ورود پس‌زمینه داخل bbox ، مقادیر پرت (outlier) در هیستوگرام depth مشاهده می‌شد.

برای کاهش اثر این مقادیر، از یک روش حذف قویه داده های پرت (مثل MAD یا IQR) استفاده شد.

روش پیشنهادی(MAD)

ابتدا میانه و MAD محاسبه شد:

$$m = \text{median}(\mathcal{V})$$
$$\text{MAD} = \text{median}(|d - m|), d \in \mathcal{V}$$

سپس Modified Z-score برای هر مقدار عمق محاسبه شد:

$$z_i = 0.6745 \cdot \frac{d_i - m}{\text{MAD}}$$

و فقط مقادیری نگه داشته شدند که:

$$|z_i| \leq \tau$$

که τمعمولاً حدود 3.5در نظر گرفته شد.

در نتیجه مجموعه نهایی عمق‌های پاک‌سازی‌شده به‌صورت $\mathcal{V}_{clean}$به دست آمد.

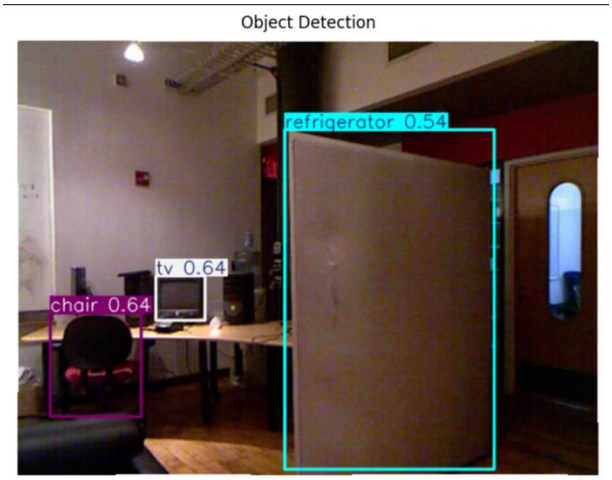
۶) تخمین فاصله شیء (به متر)

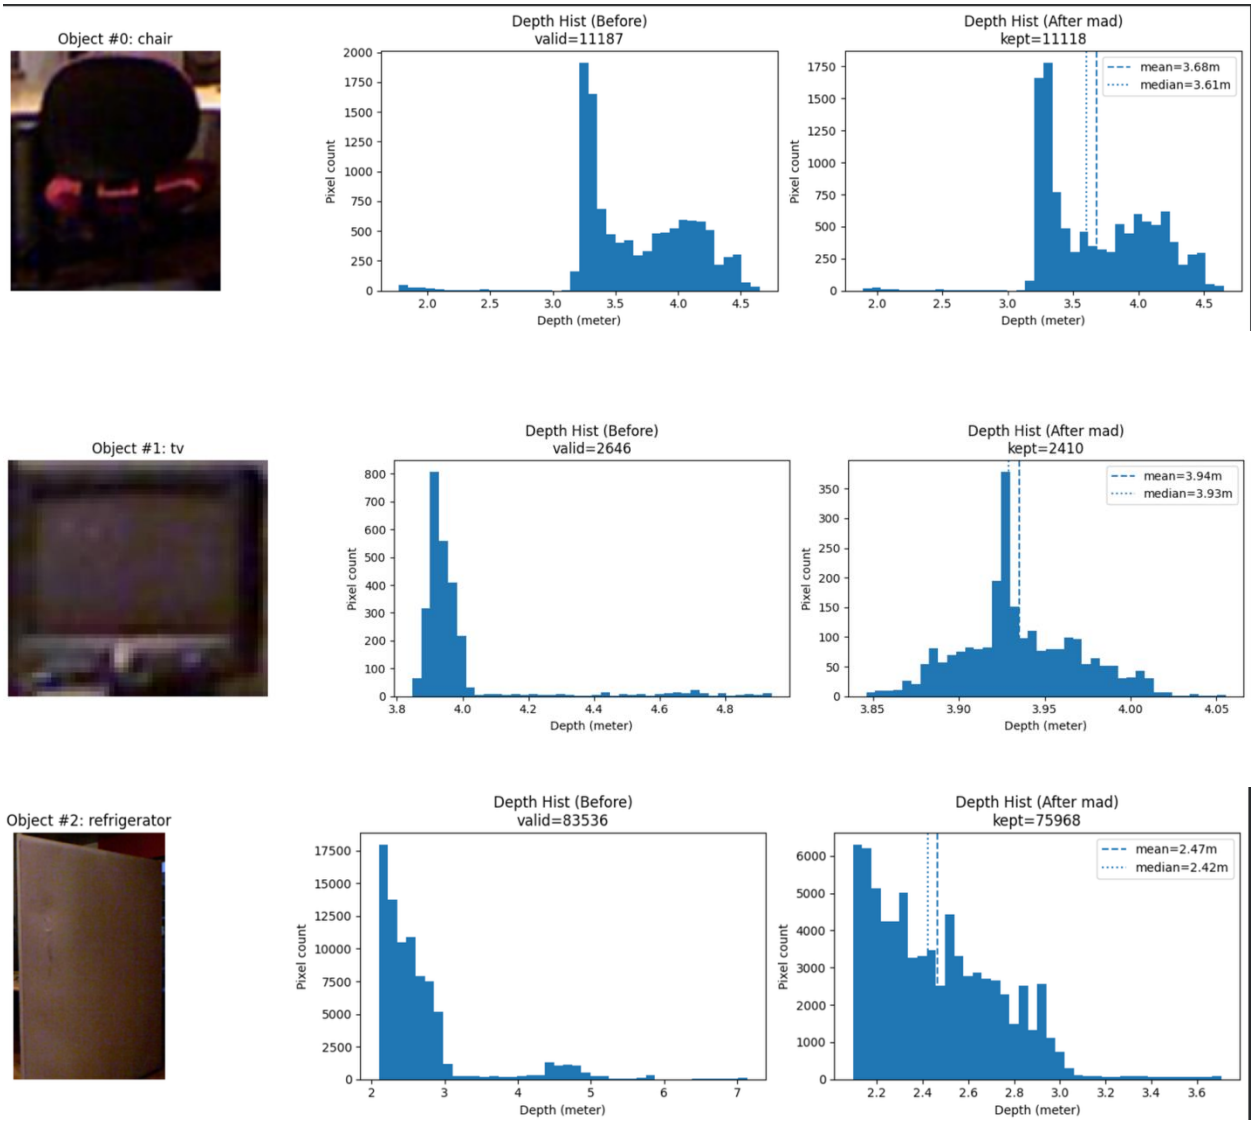
پس از حذف داده های پرت، فاصله شیء با گرفتن میانگین مقادیر عمق باقی‌مانده محاسبه شد:

$$\hat{d}_{obj} = \frac{1}{|\mathcal{V}_{clean}|} \sum_{d \in \mathcal{V}_{clean}} d$$

از آنجا که مقادیر عمق در NYU Depth V۲ برحسب متر هستند، مقدار $\hat{d}_{obj}$ مستقیماً فاصله شیء برحسب متر است.

همچنین برای پایداری بیشتر، مقدار میانه نیز قابل محاسبه و گزارش است.





شکل ۳-۷ حذف outliers و پیدا کردن عمق شي پیدا شده

فصل چهارم نتایج

۴-۱ تحلیل نتایج

مدل اشتراک گذاری توکن در مقایسه با مدل‌های دیگر موجود در تخمین عمق، نتایج بسیار خوبی به‌دست آورد:

۱. عملکرد در مقیاس‌های مختلف:

مدل TST توانسته است پیش‌بینی‌های دقیقی در مقیاس‌های مختلف ارائه دهد. این مدل همچنین توانسته است در معیارهای $\delta 1, \delta 2, \delta 3$ عملکرد بهتری نسبت به مدل‌های دیگر داشته باشد، به‌طوری که درصد بیشتری از پیش‌بینی‌های آن در محدوده از عمق واقعی قرار گرفته است.

۲. دقت بالا در پیش‌بینی عمق:

در معیار AbsRel(خطای نسبی مطلق)، مدل TST مقدار۰.۱۲۷ را به‌دست آورد که نشان‌دهنده دقت بالای پیش‌بینی عمق آن است. این مدل همچنین در معیار RMSE(ریشه مربعی خطای میانگین) مقدار ۰.۴۳۶۸و d1 مقدار ۰.۸۹۰۷ که نشاندهنده ی عملکرد بسیار خوبی هست.

۳. سرعت پردازش بالا:

یکی دیگر از مزایای مدلTST ، سرعت پردازش بالای آن است که در مقایسه با مدل‌های دیگر مانند GuidedDepth و FastDepth بسیار بهتر عمل کرده است.

۴. مقایسه با مدل‌های دیگر:

در مقایسه با مدل‌های دیگر مانند TuMDE, FastDepthو GuidedDepth مدل TST توانسته است دقت بالاتری در پیش‌بینی عمق در مقیاس‌های مختلف ارائه دهد. این نشان‌دهنده توانایی بالای مدل در پردازش اطلاعات از چندین مقیاس است.

۴-۲ نتیجه‌گیری

مدل اشتراک گذاری توکن توانسته است در تخمین عمق تک‌چشمی از تصاویر RGB نتایج بسیار خوبی به‌دست آورد و در مقایسه با سایر مدل‌های موجود عملکرد برتری از خود نشان دهد. این مدل به‌ویژه در پیش‌بینی عمق در مقیاس‌های مختلف و در شرایط پیچیده مانند نور کم و پس‌زمینه شلوغ دقت بالاتری دارد. با توجه به سرعت پردازش بالا و دقت بالای پیش‌بینی، مدل TST می‌تواند در کاربردهایی مانند رباتیک، خودروهای خودران، و سیستم‌های نظارتی به‌طور مؤثر استفاده شود.

با این حال، برای بهبود عملکرد مدل در شرایط خاص مانند نور کم یا محیط‌های پیچیده‌تر، نیاز به داده‌های بیشتر و تکنیک‌های بهینه‌سازی بیشتر وجود دارد. پیشنهاد می‌شود که در آینده، از داده‌های متنوع‌تر و تکنیک‌های داده‌افزایی پیشرفته‌تری استفاده شود تا دقت پیش‌بینی مدل در شرایط واقعی بهبود یابد.

فصل پنجم نتیجه‌گیری و پیشنهادات برای تحقیقات آینده

۵-۱ نتیجه‌گیری

در این پروژه، از مدل اشتراک گذاری توکن برای تخمین عمق تک‌چشمی از تصاویر RGB استفاده شد. این مدل توانست با استفاده از معماری‌های پیشرفته مانند توجه متقابل و (SFF) Selective Feature Fusion عملکرد بسیار خوبی در پیش‌بینی عمق از خود نشان دهد. علاوه بر این، با استفاده از مدل‌های سبک مانند MobileNetV۲ به‌عنوان انکدر، این مدل بهینه‌سازی شده است تا در دستگاه‌های کم‌مصرف مانند Jetson Nano به‌طور مؤثر اجرا شود.

نتایج حاصل از آزمایش‌ها نشان داد که مدل TST در مقایسه با مدل‌های پیشرفته دیگر مانند Adabinsو DPT دقت بالاتری در تخمین عمق از تصاویر تک‌چشمی دارد. این مدل به‌ویژه در استفاده از ویژگی‌های محلی و جهانی در مقیاس‌های مختلف عملکرد برجسته‌ای از خود نشان داد و توانست عمق را به‌طور دقیق در شرایط پیچیده، مانند نور کم و پس‌زمینه شلوغ، پیش‌بینی کند. همچنین، استفاده از تکنیک‌های افزایش داده ها و نرخ یادگیری به بهبود عملکرد مدل کمک کرد و باعث شد مدل بتواند به‌طور مؤثری در برابر داده‌های نویزی و شرایط مختلف عملکرد خوبی داشته باشد.

مدل TST توانست معیارهای مختلف ارزیابی های مختلف را بهبود دهد و پیش‌بینی عمق دقیقی ارائه دهد. به‌ویژه، استفاده از SFF و ترکیب ویژگی‌های محلی و جهانی باعث افزایش دقت پیش‌بینی عمق در مقیاس‌های مختلف شد. این مدل می‌تواند به‌طور گسترده‌ای در کاربردهای مختلف مانند رباتیک، خودروهای خودران و سیستم‌های نظارتی استفاده شود.

۵-۲ پیشنهادات برای تحقیقات آینده

با وجود نتایج خوب مدلTST ، هنوز چالش‌هایی برای بهبود بیشتر دقت پیش‌بینی عمق وجود دارد که می‌توانند در تحقیقات آینده مورد توجه قرار گیرند:

۱. افزایش دقت در شرایط پیچیده‌تر: با وجود اینکه مدل TST در شرایط معمولی و پیچیده عملکرد خوبی از خود نشان داد، در برخی شرایط خاص مانند نور کم، پس‌زمینه شلوغ یا مواردی با تغییرات شدید در عمق، عملکرد آن ممکن است دچار افت شود. تحقیقات آینده می‌توانند بر روی بهبود دقت مدل در این شرایط خاص متمرکز شوند. برای مثال، استفاده از تکنیک‌های یادگیری عمیق ترکیبی یا شبکه‌های عصبی بازگشتی[۱۸] می‌تواند به بهبود نتایج در این شرایط کمک کند.

۲. داده‌های متنوع‌تر و تکنیک‌های افزایش پیشرفته‌تر: استفاده از مجموعه داده‌های بزرگ‌تر و متنوع‌تر برای آموزش مدل می‌تواند باعث بهبود عملکرد آن در شرایط مختلف شود. علاوه بر این، استفاده از تکنیک‌های داده‌افزایی پیشرفته‌تر مانند CutMix می‌تواند کمک کند تا مدل بتواند ویژگی‌های بیشتری را یاد بگیرد و در برابر تغییرات و نویز در تصاویر مقاوم‌تر شود.

۳. استفاده از مدل‌های پیچیده‌تر برای استخراج ویژگی‌ها: در این پروژه از MobileNetV۲ به‌عنوان انکدر استفاده شد، که یک مدل سبک است و به‌طور مؤثر در دستگاه‌های کم‌مصرف اجرا می‌شود. با این حال، استفاده از مدل‌های پیچیده‌تر مانند رزنت یا ترنسفورمر بینایی می‌تواند به استخراج ویژگی‌های دقیق‌تری از تصاویر کمک کند. تحقیقات آینده می‌توانند ترکیب این مدل‌ها با TST بررسی کنند تا بتوانند دقت مدل را در مقیاس‌های مختلف بهبود دهند.

۴. توسعه مدل‌های چندوظیفه‌ای: مدل‌های چندوظیفه‌ای می‌توانند به‌طور همزمان عمق، تقسیم‌بندی تصاویر و شناسایی اشیاء را پیش‌بینی کنند. این رویکرد می‌تواند به مدل کمک کند که ویژگی‌های غنی‌تری از تصویر استخراج کرده و از این ویژگی‌ها برای پیش‌بینی دقیق‌تر عمق استفاده کند.

۵. بررسی مدل‌های تعبیه‌شده در محیط‌های واقعی: مدل TST و سایر مدل‌های مشابه باید در محیط‌های واقعی و با داده‌های واقعی آزمایش شوند. تحقیقات آینده می‌توانند به بررسی عملکرد مدل در شرایط دنیای واقعی و در تعامل با سنسورها و داده‌های مختلف پرداخته و به بهبود سازگاری و دقت مدل در کاربردهای واقعی کمک کنند.

[18] RNNs

۵-۳ نتیجه‌گیری کلی

مدل اشتراک گذاری توکن با استفاده از معماری پیشرفته و بهینه‌سازی‌های مختلف، دقت بالایی در تخمین عمق تک‌چشمی ارائه داد. نتایج آزمایش‌ها نشان می‌دهند که این مدل قادر است ویژگی‌های محلی و جهانی را به‌طور مؤثری ترکیب کند و پیش‌بینی عمق دقیقی در مقیاس‌های مختلف انجام دهد. به‌ویژه استفاده از Selective Feature Fusion و توجه متقابل به مدل این امکان را داد که عمق را با دقت بالا در شرایط پیچیده پیش‌بینی کند.

اگرچه نتایج این پروژه امیدوارکننده است، اما همچنان چالش‌هایی برای بهبود بیشتر دقت پیش‌بینی در شرایط خاص و پیچیده وجود دارد. با توجه به پتانسیل‌های موجود در مدل‌های ترکیبی و تکنیک‌های جدید داده‌افزایی، می‌توان انتظار داشت که تحقیقات آینده در این زمینه پیشرفت‌های قابل‌توجهی به‌همراه داشته باشد.

منابع:

[1] https://arxiv.org/pdf/2506.17733

[2] https://fastdepth.mit.edu/2019_icra_fastdepth.pdf

[3] https://github.com/iMoonLab/yolov13

[4] https://arxiv.org/pdf/2201.07436

[5] https://arxiv.org/pdf/2306.05682